YouBike 資料說明（給組員）

電輔車與一般車使用差異專題 ｜ 2026 年 11 月 9 日 ｜ 程式碼：`github.com/ziyingyang519/youbike-ebike-analysis`

原始資料是臺北市交通局公開的「臺北市公共自行車2.0租借紀錄」，範圍是 **2025 年 8 月到 2026 年 7 月**，共 12 個 CSV、約 9 GB、8,209 萬筆騎乘紀錄。這份文件說明資料怎麼清理、清理後有什麼，以及怎麼打開。

1. 資料怎麼清理的？為什麼？

(1) 刪除有問題的紀錄

規則	刪除筆數	為什麼
時間、站名、時長或車種缺漏	83	資料不完整，無法分析。
騎乘超過 240 分鐘	72,798	高於兩種車的第 99.9 百分位，最長甚至超過 6 天，多半是沒有正常還車或系統錯誤，會扭曲平均值。
同站借還且少於 1 分鐘	72,820	借了馬上在同一站還，通常是借車失敗（例如車子有問題）後立刻歸還，不是真正的騎乘。
合計	**145,701**	只占全部紀錄的 0.18%，不影響整體結果。

門檻是依 2026 年 3 月的資料分布訂的。各月刪除筆數記錄在 `cleaning_report.csv`，報告的「資料清理」段落可以直接引用。

(2) 整理格式

項目	怎麼改	為什麼
借還時間	「2026-03-31 16:00:00」拆成日期和時段（16）	原始資料本來就只精確到小時，拆開後比較方便分析時段，也比較省空間。
騎乘時間	「00:02:03」換算成分鐘（2.05）	原本是文字，換成數字才能計算平均、做統計。
車種	「電輔車／一般車」改成 `ebike`／`regular`	寫程式時比較方便，避免中文編碼問題。
站名	去掉前後空白、統一括號格式	同一個站可能有不同寫法，統一後才能正確比對座標。
欄位名稱	補上缺少的欄位名稱列	2025-08 到 2026-02 的原始檔沒有欄位名稱，讀取時要自動補上。
檔案格式	CSV 轉成 parquet	9 GB 縮成 396 MB；讀取一個月從幾十秒變成不到 1 秒，一般電腦的記憶體也夠用。

(3) 站名的罕用字

原始資料把「瑠、廊、舘」等罕用字寫成「?」，例如「?公公園」其實是「瑠公公園」。這項修正**沒有寫進資料檔**，而是在分析時用 `apply_name_fixes()` 套用（修正表在 GitHub 的

`data/reference/station_name_fixes.csv`）。這樣日後發現新的錯字，只要補修正表，不必重新清理整份資料。

2. 現在的資料有什麼？

檔案

檔案	內容
`trips_202508.parquet` ～ `trips_202607.parquet`	清理後的騎乘紀錄，一個月一個檔，共 12 個、8,195 萬筆
`cleaning_report.csv`	每個月原始幾筆、刪了幾筆、留下幾筆
`stations.json`	台北市 1,824 個 YouBike 站點的名稱、行政區、經緯度、車柱數

每一列是一趟騎乘，有 8 個欄位

欄位	內容	範例
`date`	借車日期	2026-03-31
`rent_hour`	借車時段（0–23 點）	16
`return_hour`	還車時段（0–23 點）	17
`rent_station`	借車站名	新生農安街口
`return_station`	還車站名	捷運中山國小站(4號出口)
`duration_min`	騎乘時間（分鐘，精確到秒）	2.05
`bike_type`	車種	`ebike` 或 `regular`
`same_station`	是否同站借還	False

分析時可以再加上的欄位

資料檔裡沒有座標。用 `add_trip_features()` 合併 `stations.json` 後，會多出：起訖站經緯度、起訖直線距離 `distance_km`、平均速度 `speed_kmh`、平日或假日 `day_type`。

使用前要注意

- **電輔車占比逐月上升**：從 2025-08 的 4.2% 升到 2026-07 的 8.5%。不同月份不能直接比較，要固定期間，或把月份當作控制變數。
- **2026-07-10、07-11 幾乎沒有資料**：可能是颱風停駛，分析時要排除這兩天。
- **約 1% 的騎乘對不上座標**：多半是騎到新北市還車（站點清單只有台北市），計算距離時會變成缺值，排除即可。
- **有營運用站點**：例如「客服中心」、「維修中心」，使用量極少，做站點分析前要排除。
- **假日目前只看週末**：國定假日和補班日還沒處理。
- **資料沒有的資訊**：沒有使用者資料（年齡、性別）、沒有騎乘路線（距離是直線距離，會低估實際距離）、借還時間只到小時。

3. 怎麼打開這些資料？

第一步：把資料放到專案裡

1. 下載專案：`git clone https://github.com/ziyingyang519/youbike-ebike-analysis.git`
2. 安裝套件：在專案資料夾執行 `pip install -r requirements.txt`
3. 從共用雲端資料夾下載資料：
   - `interim` 資料夾裡的所有檔案 → 放到專案的 `data/interim/`
   - `external` 資料夾裡的 `stations.json` → 放到專案的 `data/external/`
4. 確認程式正常：執行 `pytest`，應該顯示 9 passed。

> **parquet 檔不能直接用 Excel 開啟**，而且一個月約 700 萬筆，也超過 Excel 的上限（約 105 萬列）。請用下面的方法。原始的 9 GB CSV 也不要直接用 `pd.read_csv` 讀，記憶體可能不夠。

方法一：用專案的函式讀取（建議）

```
from youbike import load_interim, station_hour_counts

# 一個月的資料，不到 1 秒
march = load_interim("data/interim", months=["2026-03"])

# 整年電輔車的 5% 抽樣
ebike = load_interim("data/interim", bike_type="ebike", sample_frac=0.05)

# 整年的「站點 x 平日假日 x 時段 x 車種」借車次數
counts = station_hour_counts("data/interim")

march.head()
```

方法二：加上距離、速度，並修正罕用字站名

```
import pandas as pd
from youbike import load_interim, prepare_stations, apply_name_fixes, add_trip_features

stations = prepare_stations(pd.read_json("data/external/stations.json"))
fixes    = pd.read_csv("data/reference/station_name_fixes.csv")
march    = apply_name_fixes(load_interim("data/interim", months=["2026-03"]), fixes)
# 多了 distance_km、speed_kmh、day_type 等欄位
march    = add_trip_features(march, stations)
```

方法三：不用專案，直接用 pandas

```
import pandas as pd   # 需要先 pip install pandas pyarrow

df = pd.read_parquet("data/interim/trips_202603.parquet")
df.head(20)
```

方法四：想用 Excel 看幾筆

```
# 接續方法三：隨機抽 1 萬筆存成 CSV
sample = df.sample(n=10000, random_state=42)
sample.to_csv("sample_202603.csv", index=False, encoding="utf-8-sig")
```

一定要用 `encoding="utf-8-sig"`，否則 Excel 開啟時中文會變成亂碼。不想寫程式的話，也可以在 VS Code 安裝「Parquet Viewer」擴充套件，直接點開 parquet 檔瀏覽。